CỘNG ĐỒNG HỌC TẬP TRÍ TUỆ NHÂN TẠO & TÀI CHÍNH ĐỊNH LƯỢNG CHO HỌC SINH PHỔ THÔNG VÀ ĐẠI HỌC



Ước Lượng Giá Nhà Ở Việt Nam
Từ Vị Trí Và Đặc Điểm Căn Nhà (Application)

Project Leader: *Nguyễn Hoàng Đăng Khoa*

AIE for Data: *Hoàng Đình Quốc Đoàn*

AIE for Model: *Trần Minh Triết*



AIQS Community

Ước Lượng Giá Nhà Ở Việt Nam Từ Vị Trí Và Đặc Điểm Căn Nhà

(Báo Cáo Ứng Dụng: Phân Tích Dữ Liệu Tin Rao Bất Động Sản Việt Nam 2024 & Mô Hình Gradient Boosting Cho Công Cụ Ước Lượng Giá Phổ Thông)

AIQS Community[†],
[†]Nguyễn Hoàng Đăng Khoa, Hoàng Đình Quốc Đoàn, Trần Minh Triết

Tóm tắt nội dung

Báo cáo giải quyết bài toán ước lượng tổng giá rao bán một căn nhà ở Việt Nam từ những thông tin mà người không chuyên vẫn khai báo được: tỉnh/thành, quận/huyện, diện tích, mặt tiền, đường vào, số tầng, số phòng, pháp lý và nội thất. Dữ liệu là bộ Vietnam Housing Dataset 2024 gồm 30 229 tin rao có giá từ 1 đến 11.5 tỷ VND, trong đó 74% tin nằm ở Hà Nội và TP.HCM. Bước kiểm tra dữ liệu phát hiện mặt tiền và đường vào đã bị điền khuyết trên toàn bộ dữ liệu trước khi chia tập, cùng 30 tên tỉnh/thành bị tách đôi do dấu chấm thừa; cả hai đã được sửa trước khi mô hình hóa. Phân tích trên tập train cho thấy vị trí giải thích 62% phương sai của đơn giá/m^2, trong khi diện tích gần như không đi cùng tổng giá ($\rho = 0.19$): nhà càng rộng càng nằm ở vùng rẻ, hệ quả của việc dữ liệu chỉ giữ một khoảng giá. Mô hình XGBoost sau tinh chỉnh đạt MAE 0.984 tỷ VND và $R^2 = 0.645$ trên 3-fold cross-validation, ước lượng trong sai số $\pm 20\%$ cho 67% căn nhà, so với 52% của quy tắc "đơn giá quận $\times$ diện tích" mà người mua và môi giới hay dùng. Mô hình vẫn kéo giá về mức trung bình ở hai đầu phân phối và chưa được đánh giá trên tập test (mục tiêu $R^2 \geq 0.7$). Kết quả phù hợp làm ước lượng tham khảo ban đầu kèm cảnh báo trong ứng dụng, không thay thế thẩm định giá.

Mục lục

I Introduction **3**
- I.1 Bối cảnh và vấn đề . . . 3
- I.2 Mục tiêu và câu hỏi phân tích . . . 3
- I.3 Đóng góp chính . . . 3

II Domain Background **4**
- II.1 Bối cảnh lĩnh vực và thuật ngữ . . . 4
- II.2 Cơ chế vận hành của domain . . . 4
- II.3 Stakeholders và quyết định cần hỗ trợ . . . 5
- II.4 Kiến thức domain → Giả thuyết . . . 5
- II.5 Hiện trạng và các cách làm đang có . . . 5

III Data **6**
- III.1 Data Introduction . . . 6
- III.2 Data Dictionary . . . 7
- III.3 Data Quality Audit . . . 7

IV Exploratory Data Analysis **8**
- IV.1 Phân bố và thống kê mô tả . . . 8
- IV.2 Quan hệ giữa các biến . . . 9
- IV.3 Khác biệt theo vị trí và diện tích . . . 9
- IV.4 Kiểm chứng giả thuyết . . . 10

V Preprocessing & Feature Engineering **11**
- V.1 Tiền xử lý . . . 11
- V.2 Feature Engineering theo domain . . . 11
- V.3 Chia tập dữ liệu . . . 12

VI Insights: Rút Ra Được Gì Từ Data? **13**
- VI.1 Tổng hợp phát hiện chính . . . 13
- VI.2 Phát hiện bất ngờ và giả thuyết bị bác bỏ . . . 13
- VI.3 Nhóm, mẫu hình và phân khúc . . . 14
- VI.4 Từ insight đến quyết định . . . 14

VII Modeling **14**
- VII.1 Problem Formulation . . . 14
- VII.2 Baseline và lựa chọn mô hình . . . 15
- VII.3 Mô hình học được điều gì? . . . 16

VIII Evaluation **17**
- VIII.1 Chỉ số kỹ thuật . . . 17
- VIII.2 Chỉ số theo domain và giá trị thực tế . . . 18
- VIII.3 Error Analysis . . . 18
- VIII.4 Kiểm chứng với chuyên gia domain . . . 19

IX Application & Recommendations **19**
- IX.1 Cách sử dụng kết quả . . . 19
- IX.2 Khuyến nghị . . . 20
- IX.3 Giám sát và cập nhật . . . 20

X Limitations & Future Work **20**

A Data Dictionary đầy đủ **21**

B Reproducibility & Code Structure **21**

I Introduction

I.1 Bối cảnh và vấn đề

Nhà ở là khoản chi lớn nhất trong đời của phần lớn hộ gia đình Việt Nam, nhưng người mua lần đầu gần như không có công cụ nào để biết một mức giá rao là "hợp lý" hay không. Thông tin giá nằm rải rác trên các trang rao vặt, mỗi tin mô tả căn nhà theo một kiểu, và cùng một con số 6 tỷ VND có thể là một căn 40 m^2 trong ngõ ở Hà Nội hoặc một căn 120 m^2 ở ven Bình Dương. Người bán thì đặt giá rao dựa trên vài tin tương tự mà họ đã xem; môi giới định giá bằng kinh nghiệm về "đơn giá khu vực".

Cách làm phổ biến hiện nay là nhân đơn giá trung bình của khu vực với diện tích. Quy tắc này đơn giản nhưng bỏ qua số tầng, độ rộng đường vào, pháp lý, và đặc biệt sai lệch mạnh với nhà diện tích lớn ở vùng ven, nơi đơn giá thấp hơn hẳn trung bình quận. Một công cụ ước lượng dựa trên dữ liệu, giải thích được vì sao đưa ra con số đó và nói rõ khi nào không nên tin con số đó, sẽ giúp người dùng phổ thông có một điểm tham chiếu trước khi đi xem nhà hoặc thương lượng.

I.2 Mục tiêu và câu hỏi phân tích

Câu hỏi chính của báo cáo

- **Q1 (Domain):** Những yếu tố nào quyết định giá rao một căn nhà ở Việt Nam: vị trí, diện tích, kết cấu (số tầng, số phòng), hạ tầng tiếp cận (mặt tiền, đường vào), pháp lý hay yếu tố "mềm" như hướng nhà và nội thất?
- **Q2 (Data):** Bộ dữ liệu tin rao 2024 trả lời được đến đâu câu hỏi Q1? Dữ liệu bị thiếu, lệch mẫu và có nguy cơ rò rỉ ở đâu?
- **Q3 (Insight):** Data cho thấy yếu tố nào chi phối giá, yếu tố nào ít tác động hơn kỳ vọng, và mô hình sai nhiều với nhóm nhà nào?
- **Q4 (Action):** Người dùng ứng dụng, người bán và môi giới nên dùng con số ước lượng như thế nào, và ứng dụng cần cảnh báo gì?

I.3 Đóng góp chính

- **Kiểm tra và sửa dữ liệu có hệ thống:** phát hiện việc điền khuyết mặt tiền/đường vào bằng trung vị quận trên toàn bộ dữ liệu trước khi chia tập (nguy cơ rò rỉ và sai ngữ nghĩa), khôi phục giá trị gốc (`splits_v2`) và chuẩn hóa tên địa phương (106 → 76 tên tỉnh/thành trên toàn bộ dữ liệu).
- **Định lượng yếu tố quyết định giá:** vị trí giải thích 62% phương sai đơn giá/m^2; làm rõ "nghịch lý diện tích" do dữ liệu bị giới hạn khoảng giá; bác bỏ giả thuyết pháp lý và hướng nhà làm thay đổi tổng giá.
- **So sánh mô hình không rò rỉ:** từ baseline trung vị, hồi quy tuyến tính đến Random Forest, CatBoost, LightGBM, XGBoost, tất cả trên cùng các fold cố định, preprocessing học riêng trong từng fold; so sánh trực tiếp với quy tắc định giá của môi giới.
- **Khuyến nghị sử dụng:** quy trình dùng trong ứng dụng Streamlit, các cảnh báo bắt buộc (giá ngoài khoảng, quận ít dữ liệu, nhiều trường bỏ trống) và kế hoạch giám sát.

Application khác Research ở đâu?

Mục tiêu của báo cáo không phải đề xuất kiến trúc mô hình mới, mà là hiểu dữ liệu tin rao bất động sản Việt Nam đang nói gì về giá nhà, chỗ nào dữ liệu không đáng tin, và biến kết quả thành một con số tham khảo mà người dùng phổ thông dùng được một cách an toàn. Mô hình chỉ cần đủ tốt để kiểm chứng và khai thác các insight đó.

II Domain Background

II.1 Bối cảnh lĩnh vực và thuật ngữ

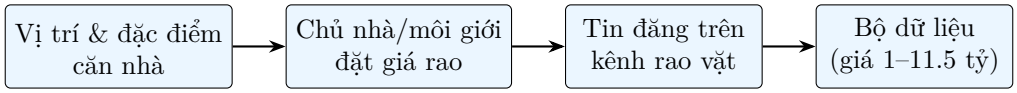
Thị trường nhà ở Việt Nam có hai đặc điểm chi phối cách đọc dữ liệu. Thứ nhất, giá gắn chặt với *đất*: ở nội đô Hà Nội và TP.HCM, phần lớn nhà là nhà phố (nhà ống) mặt tiền hẹp, xây nhiều tầng để bù diện tích đất nhỏ, nên giá phụ thuộc vào đơn giá đất của từng quận, thậm chí từng con đường. Thứ hai, tình trạng pháp lý quyết định khả năng sang tên và thế chấp: nhà có "sổ" được giao dịch, vay vốn dễ hơn nhà chỉ có hợp đồng mua bán. Bảng dưới giải thích các thuật ngữ xuất hiện trong dữ liệu.

Bảng 1: Bảng thuật ngữ domain bất động sản

Thuật ngữ	**Giải thích ngắn gọn**	**Xuất hiện ở biến**
Giá rao	Giá người bán/môi giới đăng trên tin; không phải giá giao dịch đã chốt.	`Price`
Đơn giá	Giá chia cho diện tích (triệu VND/m^2), thước đo môi giới dùng để so các khu vực.	`Price/Area`
Sổ đỏ/sổ hồng	Giấy chứng nhận quyền sử dụng đất, quyền sở hữu nhà ở; điều kiện để sang tên, thế chấp.	`Legal status` = `Have certificate`
Hợp đồng mua bán	Nhà mua theo hợp đồng với chủ đầu tư, thường là nhà dự án chưa cấp sổ.	`Legal status` = `Sale contract`
Mặt tiền	Chiều rộng cạnh nhà giáp đường (m); mặt tiền rộng thuận tiện kinh doanh.	`Frontage`
Đường vào / ngõ, hẻm	Độ rộng đường dẫn tới nhà (m); quyết định ô tô vào được hay không.	`Access Road`
Nhà phố (nhà ống)	Nhà mặt tiền hẹp, sâu, nhiều tầng; loại phổ biến ở đô thị Việt Nam.	`Floors`, `Area`
Hướng nhà	Hướng cửa chính/ban công; được quan tâm theo phong thủy.	`House/Balcony direction`
Tình trạng nội thất	Bán kèm nội thất đầy đủ (`Full`) hay cơ bản (`Basic`).	`Furniture state`

II.2 Cơ chế vận hành của domain

Một tin rao ra đời khi chủ nhà (thường qua môi giới) đặt giá dựa trên vị trí, kết cấu căn nhà và giá các tin tương tự xung quanh, rồi đăng lên kênh rao vặt. Bộ dữ liệu chỉ ghi lại *kết quả cuối* của quá trình này, và chỉ giữ các tin có giá trong một khoảng nhất định. Vì vậy dữ liệu phản ánh kỳ vọng của người bán, không phải giá thị trường đã khớp, và chịu ảnh hưởng của cách nguồn dữ liệu lọc tin.



Hình 1: Cơ chế hình thành giá rao và nơi dữ liệu được ghi lại

Trong chuỗi này, **vị trí** và **diện tích đất** là nguyên nhân chính của giá (đơn giá đất × diện tích); **số tầng, số phòng** phản ánh diện tích xây dựng và giá trị công trình; **pháp lý** ảnh hưởng tính thanh khoản; còn **hướng nhà, nội thất** là yếu tố phụ. Các biến bị bỏ trống trên tin rao không ngẫu nhiên: người đăng thường bỏ qua những trường không có lợi cho căn nhà.

II.3 Stakeholders và quyết định cần hỗ trợ

Bảng 2: Ai dùng kết quả và dùng để quyết định điều gì

Đối tượng	Quyết định họ phải đưa ra	Họ cần gì từ data/mô hình
Người mua nhà (phổ thông)	Có nên đi xem căn này không; trả giá ở mức nào.	Một khoảng giá tham khảo theo khu vực và đặc điểm căn; cảnh báo khi giá rao lệch xa.
Chủ nhà / người bán	Đặt giá rao ban đầu để bán được trong thời gian hợp lý.	Giá các căn tương tự đang rao; yếu tố nào thực sự làm tăng giá.
Môi giới	Tư vấn nhanh cho khách khi chưa có thẩm định.	Ước lượng nhanh hơn và ổn định hơn quy tắc đơn giá × diện tích.
Nhóm phát triển ứng dụng	Hiển thị con số nào, cảnh báo gì, khi nào không trả kết quả.	Sai số theo nhóm nhà, khoảng giá mô hình có cơ sở, các trường đầu vào quan trọng.

II.4 Kiến thức domain → Giả thuyết

Bảng 3: Danh sách giả thuyết

ID	Giả thuyết	Cơ sở từ domain	Biến liên quan
H1	Vị trí (tỉnh, quận) là yếu tố quyết định đơn giá/m^2.	Giá đất khác nhau nhiều lần giữa nội đô và vùng ven; môi giới định giá theo "đơn giá khu vực".	`City`, `District`
H2	Nhà diện tích lớn hơn có tổng giá cao hơn.	Giá ≈ đơn giá × diện tích.	`Area`
H3	Nhà có sổ có giá cao hơn nhà chỉ có hợp đồng mua bán.	Sổ giúp sang tên, thế chấp dễ; nhà chưa sổ chịu rủi ro pháp lý.	`Legal status`
H4	Nhà nhiều tầng, nhiều phòng tắm/WC có giá cao hơn.	Nhà phố xây cao để tăng diện tích sàn; nhiều WC phản ánh diện tích sàn và chất lượng.	`Floors`, `Bathrooms`, `Bedrooms`
H5	Hướng nhà "đẹp" theo phong thủy làm tăng giá.	Người mua Việt Nam quan tâm hướng Đông Nam, Nam.	`House direction`
H6	Nhà bán kèm nội thất đầy đủ có giá cao hơn.	Nội thất cộng thêm giá trị sử dụng ngay.	`Furniture state`

II.5 Hiện trạng và các cách làm đang có

- **Định giá theo phương pháp so sánh** (thẩm định viên, môi giới): so với vài giao dịch/tin rao tương tự gần đó rồi điều chỉnh theo khác biệt. Chính xác khi người làm hiểu khu vực, nhưng tốn thời gian, phụ thuộc kinh nghiệm cá nhân và không có sẵn cho người dùng phổ thông.

- **Bảng giá đất do UBND cấp tỉnh ban hành:** phục vụ tính thuế, phí, bồi thường; không được thiết kế để phản ánh giá rao của từng căn nhà cụ thể.

- **Quy tắc "đơn giá khu vực × diện tích":** cách ước lượng nhanh phổ biến nhất. Báo cáo dựng lại quy tắc này trên chính dữ liệu (trung vị đơn giá của quận học từ phần train

của mỗi fold) để làm mốc so sánh: chỉ 52% căn nhà được ước lượng trong sai số ±20% (mục VIII.2).

Khoảng trống mà báo cáo lấp vào: một ước lượng dùng đồng thời nhiều đặc điểm căn nhà, được đánh giá trung thực trên dữ liệu chưa thấy, và đi kèm thông tin về độ tin cậy theo từng nhóm nhà.

Lỗi thường gặp ở mục Domain

Không gọi output là "giá thị trường" hay "giá giao dịch". Dữ liệu là giá rao do người bán đặt; nhóm chưa xác minh được dữ liệu đã được nguồn xử lý thế nào, nên mọi kết luận ở đây là về giá rao trong khoảng 1–11.5 tỷ VND.

III Data

III.1 Data Introduction

Dữ liệu là bộ *Vietnam Housing Dataset 2024* công bố trên Kaggle, gồm 30 229 tin rao bán nhà, mỗi dòng là một căn nhà với 11 thuộc tính mô tả và giá. Nhóm chọn bộ dữ liệu này vì có quy mô lớn, phủ nhiều tỉnh thành, và các thuộc tính đều là thông tin mà người dùng phổ thông tự khai báo được, đúng với kịch bản ứng dụng. Cột `Address` được tách thành `City` (phần cuối) và `District` (phần áp chót); số nhà và tên đường bị loại vì quá chi tiết và không chuẩn hóa được.

Bảng 4: Tổng quan bộ dữ liệu

Thuộc tính	**Mô tả**
Nguồn	Kaggle — Vietnam Housing Dataset 2024 (`data/vietnam_housing_dataset.csv`)
Khoảng thời gian	Tin rao năm 2024 (ảnh chụp một thời điểm, không có ngày đăng từng tin)
Đơn vị quan sát	Một dòng = một tin rao bán một căn nhà
Số dòng / số cột	30 229 dòng; 12 cột gốc → 13 cột sau khi tách địa chỉ
Phạm vi địa lý	106 tên tỉnh/thành, 341 tên quận/huyện gốc; 74% tin ở Hà Nội và TP.HCM
Tần suất cập nhật	Không cập nhật (bộ dữ liệu tĩnh)
Biến mục tiêu	`Price`: tổng giá rao, đơn vị tỷ VND, khoảng 1.0–11.5
Giấy phép sử dụng	Theo điều khoản trang Kaggle của bộ dữ liệu; dùng cho mục đích học tập

III.2 Data Dictionary

Bảng 5: Các biến then chốt (tỷ lệ thiếu trên dữ liệu gốc)

Biến	Kiểu	Đơn vị	Ý nghĩa theo domain	% thiếu
`Price`	Số thực	tỷ VND	Tổng giá rao (biến mục tiêu)	0.0
`City`	Phân loại	–	Tỉnh/thành, tách từ địa chỉ	0.0
`District`	Phân loại	–	Quận/huyện, tách từ địa chỉ	0.0
`Area`	Số thực	m^2	Diện tích ghi trên tin (nhóm chưa xác minh là diện tích đất hay sàn)	0.0
`Floors`	Số nguyên	tầng	Số tầng; đại diện cho diện tích xây dựng	11.9
`Bathrooms`	Số nguyên	phòng	Số phòng tắm/WC	23.4
`Access Road`	Số thực	m	Độ rộng đường/ngõ vào nhà	44.0
`Legal status`	Phân loại	–	`Have certificate` / `Sale contract`	14.9
`Furniture state`	Phân loại	–	`Full` / `Basic`	46.7

Bảng đầy đủ 13 biến nằm ở Phụ lục A. Có tới 91% tin trong tập train bị thiếu ít nhất một trong 9 trường tùy chọn; chỉ 8.7% tin khai báo đầy đủ.

III.3 Data Quality Audit

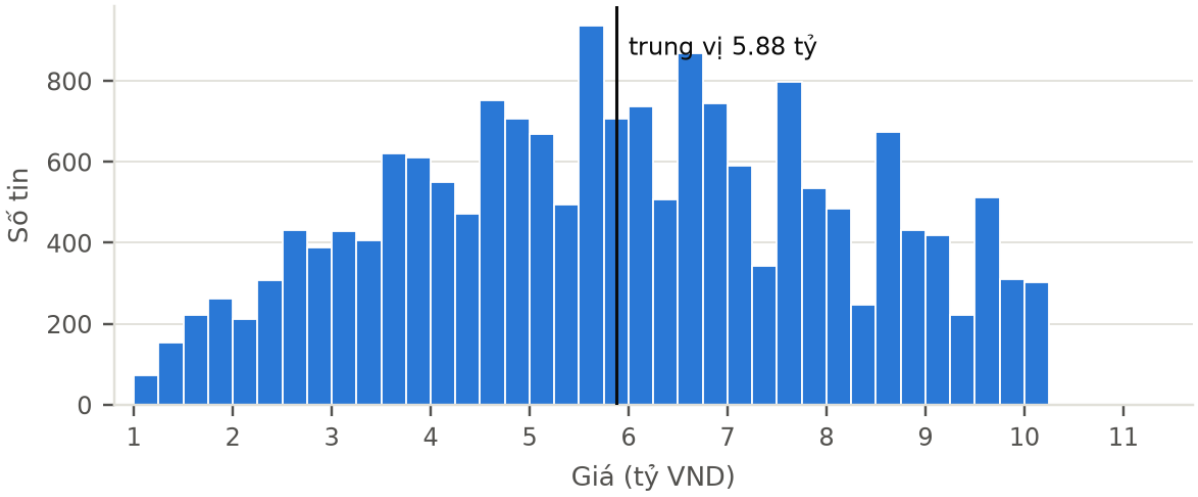
Bảng 6: Kiểm tra chất lượng dữ liệu và phương án xử lý

Vấn đề	Phát hiện	Mức độ	Cách xử lý	Lý do
Giá trị thiếu	9/12 cột thiếu 12–83%; hướng ban công thiếu 82.6%.	Cao	Điền trong pipeline (số: mean sau chuẩn hóa; phân loại: mode), học riêng trong từng fold.	Không bỏ dòng; tránh dùng thông tin tập đánh giá.
Điền khuyết trước khi chia tập	Bản `_v1` đã điền `Frontage`/`Access Road` bằng trung vị quận trên toàn bộ 30 229 dòng; ô còn thiếu gán 0 và 2.0. Đã tái lập đúng công thức.	Cao	Khôi phục giá trị gốc thành `splits_v2`, giữ nguyên thành viên các tập; điền lại trong pipeline.	Chống rò rỉ; mặt tiền = 0 sai ngữ nghĩa.
Tên địa phương không thống nhất	"Hà Nội." và "Hà Nội" là hai giá trị; 509 dòng train đổi tên.	Trung bình	Chuẩn hóa NFC, khoảng trắng, dấu chấm cuối: 106 → 76 tên tỉnh/thành.	Gộp nhóm bị tách giả tạo.
Trùng lặp	0 dòng trùng toàn bộ ở dữ liệu gốc; 202 dòng (0.67%) trùng sau khi rút gọn địa chỉ.	Thấp	Giữ nguyên.	Trùng thuộc tính không chứng minh trùng căn nhà.
Giá trị bất thường	41 tin dưới 15 m^2; đơn giá tới 1 600 triệu VND/m^2; 131 tin có số phòng ngủ $> 3\times$ số tầng.	Thấp	Đánh dấu, không xóa.	Mô hình cây và MAE ít nhạy với ngoại lệ.
Lệch mẫu	Giá chỉ trong 1–11.5 tỷ VND; 74% tin ở HN và TP.HCM; 226/302 quận có < 30 tin train.	Cao	Ghi rõ phạm vi áp dụng; cảnh báo trong app.	Mô hình không có cơ sở ngoài phạm vi này.
Nguy cơ rò rỉ	`row_id`, đơn giá/m^2 tính từ `Price`.	Cao	Loại khỏi đặc trưng; khóa test và calibration.	Chỉ dùng thông tin có lúc dự đoán.

IV Exploratory Data Analysis

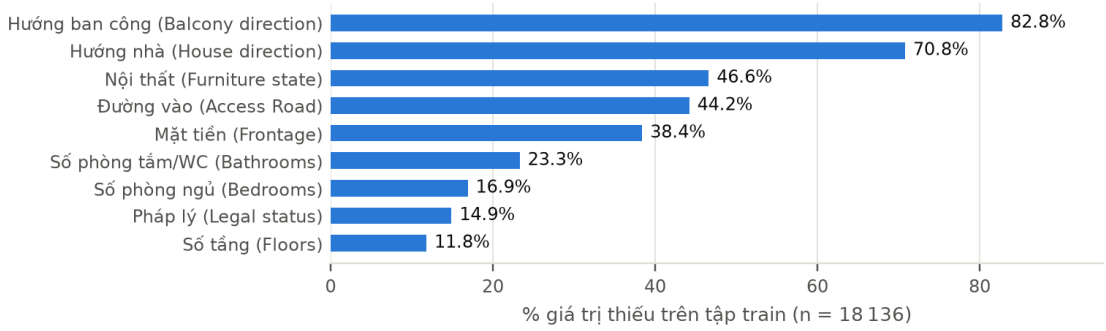
Toàn bộ phân tích trong mục này chỉ dùng tập train (18 136 dòng, `splits_v2`); tập calibration và test không được mở để tránh việc chọn mô hình dựa trên dữ liệu đánh giá cuối.

IV.1 Phân bố và thống kê mô tả



Hình 2: Phân bố giá rao trên tập train (bước 0.25 tỷ VND)

Giá có trung vị 5.88 tỷ VND, trung bình 5.87 tỷ VND, độ lệch chuẩn 2.21 tỷ VND và độ lệch (skewness) gần 0 (-0.02). Đây là dấu hiệu bất thường: giá bất động sản thực tế gần như luôn lệch phải với đuôi dài ở phân khúc cao cấp. Phân bố cân đối và bị chặn gọn trong 1–11.5 tỷ VND cho thấy nguồn dữ liệu đã lọc tin theo khoảng giá. Diện tích có trung vị 56 m^2 (từ 4 đến 595 m^2), còn đơn giá có trung vị 103 triệu VND/m^2 với 90% giá trị trong khoảng 28–206 triệu VND/m^2.



Hình 3: Tỷ lệ thiếu theo trường trên tập train

Hai trường hướng nhà, hướng ban công thiếu trên 70%; nội thất, đường vào, mặt tiền thiếu 38–47%. Các trường "mềm" bị bỏ trống nhiều nhất, khớp với cơ chế người đăng tin chỉ điền những gì họ cho là quan trọng.

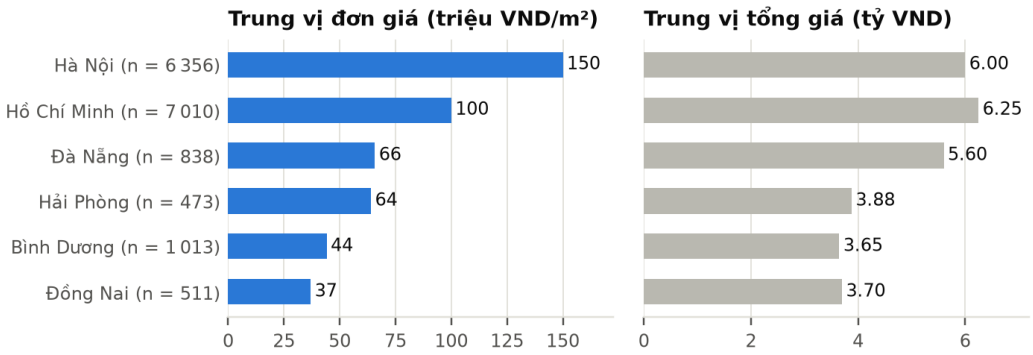
IV.2 Quan hệ giữa các biến

Bảng 7: Tương quan hạng Spearman giữa biến số và giá (tập train, bỏ dòng thiếu theo cặp)

Biến	n	ρ với giá	Nhận xét
Số phòng tắm/WC (`Bathrooms`)	13 908	0.462	Mạnh nhất trong nhóm biến số
Số phòng ngủ (`Bedrooms`)	15 077	0.425	Đi cùng diện tích sàn
Số tầng (`Floors`)	15 991	0.325	Nhà phố nhiều tầng giá cao hơn
Đường vào (`Access Road`)	10 126	0.245	Ngõ rộng, ô tô vào được
Diện tích (`Area`)	18 136	0.193	Yếu hơn kỳ vọng (xem IV.3)
Mặt tiền (`Frontage`)	11 177	0.112	Yếu
Diện tích với *đơn giá*	18 136	−0.697	Nhà càng rộng, đơn giá càng thấp

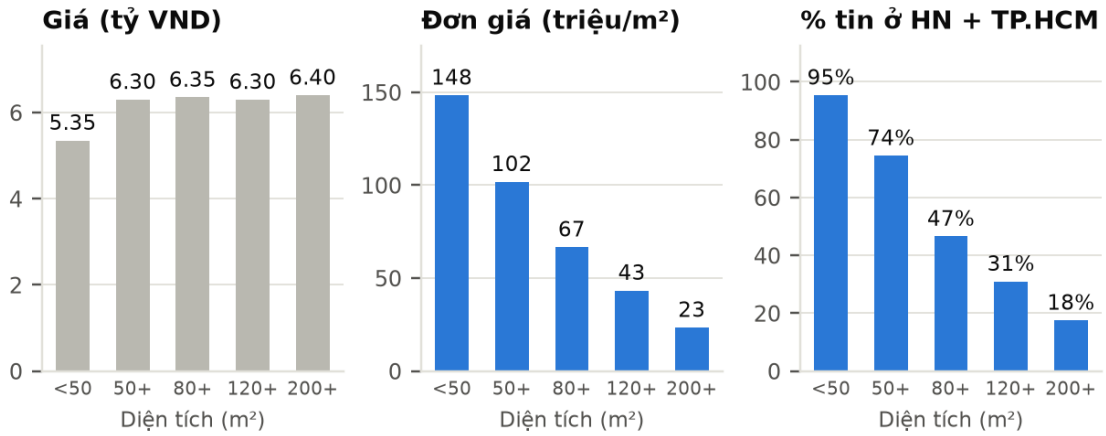
Với biến phân loại, nhóm dùng tỷ số tương quan η^2 (tỷ lệ phương sai của giá được giải thích bởi trung bình từng nhóm). Cặp tỉnh + quận giải thích 24.9% phương sai tổng giá và 61.8% phương sai đơn giá; tình trạng nội thất 3.7%; hướng nhà 0.5%; pháp lý gần 0%.

IV.3 Khác biệt theo vị trí và diện tích



Hình 4: Đơn giá và tổng giá theo 6 tỉnh/thành nhiều tin nhất (trung vị, tập train)

Đơn giá ở Hà Nội (150 triệu VND/m^2) gấp 4 lần Đồng Nai (37 triệu VND/m^2), nhưng tổng giá chỉ chênh 1.6 lần: người mua ở Hà Nội nhận diện tích nhỏ hơn hẳn (trung vị 40 m^2 so với 100 m^2). Nói cách khác, vị trí quyết định *đơn giá*, còn diện tích "co giãn" để tổng giá vừa với khả năng chi trả.



Hình 5: Theo nhóm diện tích (m^2; "50+" nghĩa là 50 đến dưới 80, ...): tổng giá trung vị gần như đi ngang, đơn giá giảm mạnh và tỷ lệ tin ở Hà Nội + TP.HCM giảm theo

Từ 50 m^2 trở lên, tổng giá trung vị đứng yên quanh 6.3–6.4 tỷ VND dù diện tích tăng gấp bốn. Cùng lúc, tỷ lệ tin ở Hà Nội và TP.HCM giảm từ 95% (nhóm dưới 50 m^2) xuống 18% (nhóm từ 200 m^2). Diện tích lớn không làm giá cao hơn vì nhà diện tích lớn *chỉ lọt vào khoảng 1–11.5 tỷ VND khi nằm ở vùng giá rẻ.*

IV.4 Kiểm chứng giả thuyết

Bảng 8: Kết quả kiểm chứng giả thuyết (tập train)

ID	Phương pháp	Kết quả	Effect size	Kết luận
H1	Kruskal–Wallis, η^2 trên đơn giá	302 nhóm tỉnh–quận, $p < 10^{-300}$	$\eta^2 = 0.618$ (lớn)	**Chấp nhận**: vị trí quyết định đơn giá.
H2	Spearman `Area`–`Price`	$\rho = 0.193$; giá đi ngang từ 50 m^2	Nhỏ	**Bác bỏ ở mức toàn bộ dữ liệu**; chỉ đúng khi cố định vị trí (mục VII.3).
H3	Mann–Whitney, có sổ vs HĐMB	Trung vị 5.85 vs 6.00 tỷ VND; $p = 0.88$	Cliff's $\delta = 0.004$	**Bác bỏ** với tổng giá.
H4	Spearman	`Bathrooms` 0.46; `Floors` 0.33	Trung bình	**Chấp nhận**.
H5	Kruskal–Wallis, 8 hướng	$p = 0.0009$; trung vị 5.05–5.60 tỷ VND	$\eta^2 = 0.005$	**Bác bỏ về thực tiễn**: có ý nghĩa thống kê nhưng hiệu ứng không đáng kể.
H6	Mann–Whitney, Full vs Basic	Trung vị 6.20 vs 5.00 tỷ VND; $p < 10^{-78}$	Cliff's $\delta = 0.233$	**Chấp nhận yếu**; biến mất khi có các biến khác (VII.3).

Tương quan không phải nhân quả

Nhà có sổ có *đơn giá* cao gấp đôi nhà hợp đồng mua bán (106.6 so với 52.9 triệu VND/m^2, Cliff's $\delta = 0.54$), nhưng không thể kết luận "có sổ làm giá tăng gấp đôi". Tin hợp đồng mua bán tập trung ở dự án vùng ven (Đồng Nai, Hưng Yên, Bình Dương chiếm 34%) với diện tích trung vị 100 m^2: vị trí và loại hình nhà là biến thứ ba giải thích phần lớn khác biệt. Tương tự, nội thất đầy đủ đi cùng nhà nhỏ nội đô, nên hiệu ứng của nội thất lẫn với hiệu ứng vị trí.

V Preprocessing & Feature Engineering

V.1 Tiền xử lý

Mọi bước tiền xử lý nằm trong một `Pipeline` của scikit-learn và được fit lại trong từng fold, nên không có thống kê nào (trung bình, mode, danh mục) được học từ phần dữ liệu dùng để chấm điểm.

1. **Chuẩn hóa địa danh:** Unicode NFC, gộp khoảng trắng, bỏ dấu chấm cuối cho `City`, `District`. Trên Random Forest, MAE validation của 120 dòng đổi tên giảm từ 1.030 xuống 0.853 tỷ VND.
2. **Biến số:** chuẩn hóa (StandardScaler) rồi điền thiếu bằng trung bình. Nhóm đã so sánh trên validation: mean tốt hơn median (MAE 1.0188 so với 1.0212), tốt hơn KNN với $k = 3, 5, 15$ (1.0237–1.0254) và thêm cờ thiếu không cải thiện (1.0236).
3. **Biến phân loại:** điền mode rồi One-Hot (`handle_unknown="ignore"` để quận mới không làm lỗi pipeline). Gán nhãn riêng `__MISSING__` cho ô thiếu cho kết quả kém hơn mode (1.0219 so với 1.0175). Sau mã hóa có 388 cột.

V.2 Feature Engineering theo domain

Bảng 9: Các đặc trưng được tạo thêm hoặc đã thử

Đặc trưng	Cách tính	Ý nghĩa theo domain	Trạng thái
`City`, `District`	Tách `Address` theo dấu phẩy, lấy 2 phần cuối	Đại diện đơn giá đất khu vực (H1)	Dùng
Địa danh chuẩn hóa	NFC, bỏ dấu chấm, khoảng trắng	Gộp các biến thể của cùng một nơi	Dùng
Cờ thiếu dữ liệu	`isna()` cho 3 biến số	"Không khai báo" có thể mang thông tin	Đã thử, bỏ
Nhãn `__MISSING__`	Danh mục riêng cho ô trống	Như trên, cho biến phân loại	Đã thử, bỏ
Đơn giá/m^2	`Price / Area`	Thước đo của môi giới	Chỉ dùng cho EDA (rò rỉ nhãn)
`City_District`	Ghép tỉnh và quận	Phân biệt quận trùng tên giữa các tỉnh	Kế hoạch

Pipeline tiền xử lý dùng chung cho các mô hình cây

```
import re
import unicodedata
import pandas as pd
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import (FunctionTransformer, OneHotEncoder,
                                   StandardScaler)

NUM = ["Area", "Frontage", "Access Road",
       "Floors", "Bedrooms", "Bathrooms"]
CAT = ["House direction", "Balcony direction", "Legal status",
       "Furniture state", "City", "District"]

def normalize_location_frame(X):
    # Chuan hoa ten dia phuong: NFC, gop khoang trang, bo dau cham cuoi
```

```
    X = X.copy()
    def norm(v):
        if pd.isna(v):
            return v
        v = unicodedata.normalize("NFC", str(v))
        return re.sub(r"\s+", " ", v).strip().rstrip(".").strip()
    for col in ["City", "District"]:
        X[col] = X[col].map(norm)
    return X

# So: chuan hoa roi dien mean; phan loai: dien mode roi One-Hot
num_pipe = Pipeline([("scaler", StandardScaler()),
                     ("imputer", SimpleImputer())])
cat_pipe = Pipeline([("imputer", SimpleImputer(strategy="most_frequent")),
                     ("onehot", OneHotEncoder(handle_unknown="ignore"))])

preprocessing = Pipeline([
    ("normalize_location", FunctionTransformer(normalize_location_frame)),
    ("columns", ColumnTransformer([("num", num_pipe, NUM),
                                   ("cat", cat_pipe, CAT)])),
])
```

V.3 Chia tập dữ liệu

Mỗi dòng là một căn nhà riêng và mục tiêu là ước lượng cho căn nhà khác trong cùng bối cảnh, không dự báo tương lai, nên nhóm chia ngẫu nhiên với `seed = 42` và cố định từ đầu dự án:

Bảng 10: Giao thức chia dữ liệu

Tập	Tỷ lệ	Số dòng	Vai trò
Train	60%	18 136	Fit tiền xử lý và mô hình; 3-fold CV cố định để chọn mô hình, tham số
Validation	15%	4 535	So sánh nhanh ở giai đoạn khám phá, early stopping thử nghiệm
Calibration	10%	3 023	Hiệu chỉnh khoảng dự đoán sau khi khóa mô hình (chưa dùng)
Test	15%	4 535	Đánh giá cuối một lần duy nhất (chưa dùng)

Bốn tập không giao nhau theo `row_id` và được lưu thành file; khi sửa dữ liệu, nhóm tạo phiên bản mới (`splits_v2`) nhưng giữ nguyên thành viên từng tập để các kết quả so sánh được với nhau.

VI Insights: Rút Ra Được Gì Từ Data?

VI.1 Tổng hợp phát hiện chính

Bảng 11: Các phát hiện chính từ data

#	Phát hiện	Bằng chứng	Giải thích theo domain	Hành động	Độ tin cậy
1	Vị trí quyết định đơn giá	$\eta^2 = 0.62$ trên đơn giá; HN 150 vs Đồng Nai 37 triệu VND/m^2	Giá đất theo khu vực là thành phần lớn nhất của giá nhà	Bắt buộc nhập tỉnh và quận trong app	Cao
2	"Nghịch lý diện tích"	Giá đi ngang 6.3 tỷ VND từ 50 m^2; $\rho(\text{diện tích}, \text{đơn giá}) = -0.70$	Dữ liệu chỉ giữ 1–11.5 tỷ VND: nhà rộng chỉ lọt vào nếu ở vùng rẻ	Không đọc diện tích tách khỏi vị trí	Cao
3	Kết cấu quan trọng hơn diện tích đơn lẻ	ρ WC 0.46, tầng 0.33 so với diện tích 0.19	Nhà phố xây cao bù đất nhỏ; số tầng/WC đo diện tích sàn	Hỏi số tầng, WC; cảnh báo khi bỏ trống	Trung bình
4	Pháp lý không làm khác tổng giá	$\delta = 0.004$, $p = 0.88$	"Hợp đồng mua bán" là nhà dự án vùng ven, diện tích lớn	Không coi "có sổ" là điểm cộng giá độc lập	Trung bình
5	Mô hình kéo giá về trung bình	Nhà < 3 tỷ bị đoán cao $+0.97$; nhà ≥ 9 tỷ bị đoán thấp -1.74	Thiếu thông tin chi tiết (vị trí trong quận, chất lượng)	Hiện khoảng giá và cảnh báo ở hai đầu	Cao
6	Hướng nhà, nội thất gần như không đóng góp	Permutation importance < 0.01 tỷ VND	Yếu tố phụ, lẫn với vị trí	Để là trường tùy chọn	Cao

VI.2 Phát hiện bất ngờ và giả thuyết bị bác bỏ

Nghịch lý diện tích (H2). Kỳ vọng ban đầu là "nhà càng rộng càng đắt". Ở mức toàn bộ dữ liệu, điều này gần như không đúng: tương quan chỉ 0.19 và tổng giá đi ngang từ 50 m^2. Nguyên nhân là *selection bias* do nguồn chỉ giữ tin 1–11.5 tỷ VND: một căn 200 m^2 ở nội đô Hà Nội có giá vượt xa 11.5 tỷ VND nên không có mặt trong dữ liệu; căn 200 m^2 còn lại thường ở Bình Dương, Đồng Nai. Khi giữ vị trí cố định, diện tích lại là đặc trưng quan trọng nhất của mô hình (mục VII.3). Đây là trường hợp điển hình của nghịch lý Simpson: quan hệ trong từng nhóm khác với quan hệ khi gộp các nhóm.

Pháp lý (H3) và phong thủy (H5). Hai yếu tố được bàn nhiều khi mua nhà lại gần như không giải thích được tổng giá trong dữ liệu này. Với pháp lý, khác biệt đơn giá có thật nhưng bị nhiễu bởi vị trí và loại hình nhà; dữ liệu không có biến "nhà dự án / nhà thổ cư" để tách hai hiệu ứng. Với hướng nhà, khác biệt trung vị giữa các hướng (5.05–5.60 tỷ VND) nhỏ hơn nhiều so với độ biến động trong từng hướng.

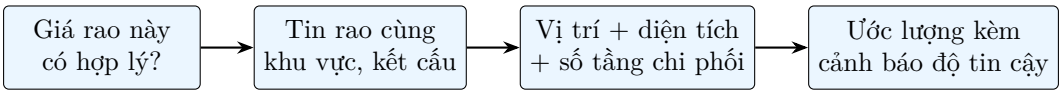
VI.3 Nhóm, mẫu hình và phân khúc

Bảng 12: Phân khúc theo vị trí và diện tích (tập train; sai số từ dự đoán out-of-fold của XGBoost)

Phân khúc	n	Giá (tỷ)	Đơn giá (tr/m^2)	MAE	MdAPE
Nhà nhỏ Hà Nội (<50 m^2)	4 807	5.68	158	0.93	13.1%
Nhà phố Hà Nội (50–100 m^2)	1 453	7.60	129	1.20	12.9%
Nhà nhỏ TP.HCM (<50 m^2)	2 027	4.60	130	0.78	13.1%
Nhà phố TP.HCM (50–100 m^2)	4 177	6.59	99	0.95	11.4%
Nhà lớn TP.HCM (≥ 100 m^2)	806	7.70	62	1.17	12.4%
Tỉnh khác (50–100 m^2)	2 513	4.30	59	0.93	14.8%
Tỉnh khác (≥ 100 m^2)	1 926	5.50	38	1.19	17.2%

Có thể gọi tên bốn nhóm theo ngôn ngữ thị trường: *nhà nhỏ Hà Nội* (đất nhỏ, đơn giá rất cao), *nhà phố TP.HCM* (nhóm đông nhất, mô hình dự đoán tốt nhất, MdAPE 11.4%), *nhà đất vùng ven* (diện tích lớn, đơn giá thấp, sai số tương đối cao hơn) và *nhà dự án chưa có sổ* (545 tin, đơn giá 53 triệu VND/m^2). MAE tuyệt đối tăng theo giá trị căn nhà, nhưng sai số tương đối lớn nhất lại nằm ở các tỉnh ngoài Hà Nội và TP.HCM, nơi mỗi quận có ít tin để mô hình học.

VI.4 Từ insight đến quyết định



Hình 6: Chuỗi giá trị của báo cáo: từ câu hỏi của người mua đến con số có kèm điều kiện sử dụng

Một insight tốt phải trả lời được ba câu

(1) **Bằng chứng:** tổng giá đi ngang quanh 6.3 tỷ VND từ 50 m^2 trong khi đơn giá giảm từ 148 xuống 23 triệu VND/m^2 và tỷ lệ tin ở Hà Nội + TP.HCM giảm từ 95% xuống 18%. (2) **Cơ sở domain:** giá nhà $\approx$ đơn giá đất khu vực $\times$ diện tích; dữ liệu lọc theo khoảng giá nên nhà rộng chỉ xuất hiện ở vùng rẻ. (3) **Hành động:** không bao giờ so sánh giá hai căn chỉ theo diện tích; ứng dụng phải bắt buộc nhập vị trí và từ chối ước lượng ngoài khoảng mà dữ liệu bao phủ.

VII Modeling

VII.1 Problem Formulation

Bài toán là hồi quy có giám sát trên dữ liệu bảng. Với mỗi căn nhà i có vector đặc trưng $\mathbf{x}_i$ gồm 12 biến (6 số, 6 phân loại), mô hình học hàm f sao cho

$$\hat{P}_i = f(\mathbf{x}_i), \qquad \text{MAE} = \frac{1}{n}\sum_{i=1}^{n}\left|P_i - \hat{P}_i\right|,$$

trong đó P_i là giá rao (tỷ VND). MAE là metric chọn mô hình vì cùng đơn vị với giá và người dùng hiểu ngay ("sai trung bình bao nhiêu tỷ"); RMSE theo dõi lỗi lớn; R^2 là tiêu chí nghiệm

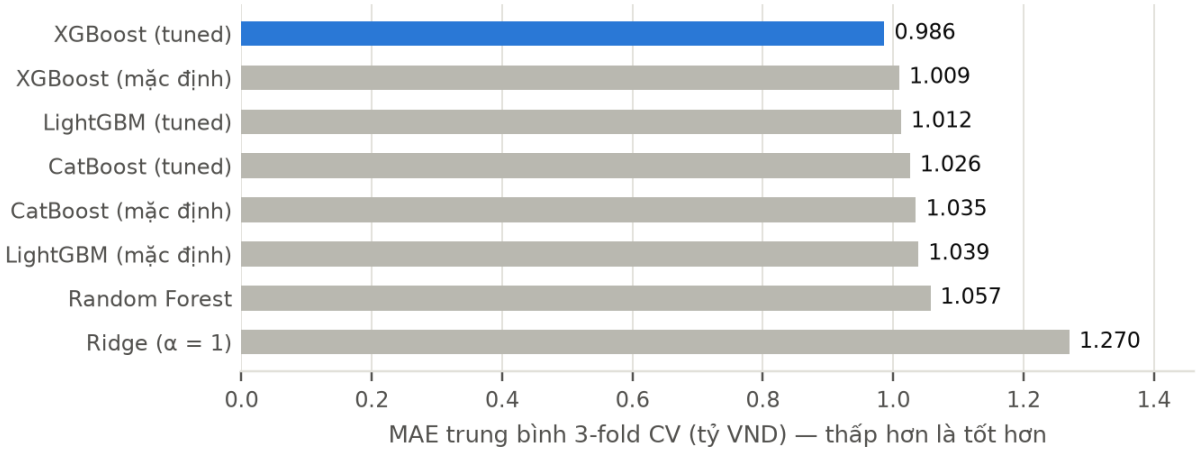
thu của dự án ($R^2 \geq 0.7$ trên tập test). Ràng buộc: chỉ dùng thông tin người dùng khai báo được lúc dự đoán; pipeline phải chịu được trường bỏ trống và quận chưa từng thấy.

VII.2 Baseline và lựa chọn mô hình

Nhóm đi từ đơn giản đến phức tạp. Giai đoạn đầu so sánh nhanh trên tập validation; sau đó chuyển sang 3-fold cross-validation trên tập train để có ước lượng ổn định hơn và dùng cho tinh chỉnh tham số.

Bảng 13: Giai đoạn khám phá: so sánh trên tập validation (`splits_v1`, 4 535 dòng). Ba mô hình boosting dùng chính tập validation để dừng sớm nên điểm của chúng hơi lạc quan.

Mô hình	MAE	RMSE	R^2	Ghi chú
Baseline: trung vị giá train (5.88 tỷ)	1.825	2.190	0.000	Mốc sàn
Hồi quy tuyến tính	1.264	1.643	0.437	Thiếu quan hệ phi tuyến
Ridge ($\alpha = 1$)	1.256	1.624	0.450	Điều chuẩn cải thiện rất ít
Random Forest (mặc định)	1.024	1.388	0.598	Train R^2 0.935: overfit
CatBoost (3 000 vòng)	0.991	1.315	0.639	Fit chậm nhất
LightGBM (early stopping)	0.986	1.320	0.637	Fit 3 giây
XGBoost (3 000 vòng)	0.981	1.327	0.633	MAE thấp nhất



Hình 7: So sánh 8 pipeline trên cùng 3 fold cố định của tập train (`splits_v1`)

Tinh chỉnh bằng grid search trên cùng 3 fold, chọn theo MAE trung bình; trong mỗi fold, số cây được chọn bằng early stopping trên 15% phần train của fold rồi refit, nên phần đánh giá không tham gia chọn số cây.

Bảng 14: Kết quả grid search lượt 1 (MAE 3-fold CV, tỷ VND)

Mô hình	Số cấu hình	Cấu hình chọn	Trước	Sau
Random Forest	144	`max_features`=0.7, cây không giới hạn độ sâu	1.057	1.057
CatBoost	27	`depth`=8, `l2_leaf_reg`=3, `random_strength`=2	1.035	1.026
LightGBM	36	`num_leaves`=63, `min_child_samples`=10	1.039	1.012
XGBoost	36	`max_depth`=9, `subsample`=0.8, `colsample_bytree`=0.7	1.009	**0.986**

Hai ứng viên được giữ lại là **XGBoost** (sai số thấp nhất) và **LightGBM** (sai số gần tương đương, huấn luyện nhanh hơn khoảng 8 lần). Sau khi sửa lỗi điền khuyết trước khi chia tập, cả hai được huấn luyện lại trên `splits_v2` và lưu checkpoint ngày 16/10/2026:

Bảng 15: Hai ứng viên trên `splits_v2` (trung bình 3 fold)

Mô hình	MAE	RMSE	R^2	Train MAE	Số cây chọn (3 fold)
XGBoost	0.984	1.319	0.645	0.553	738 / 1 141 / 804
LightGBM	1.016	1.352	0.627	0.757	384 / 343 / 367

Sau khi bỏ giá trị điền sẵn, XGBoost không giảm chất lượng (MAE 0.986 → 0.984), cho thấy điểm số trước đó không bị thổi phồng đáng kể bởi lỗi dữ liệu.

Cấu hình XGBoost được chọn

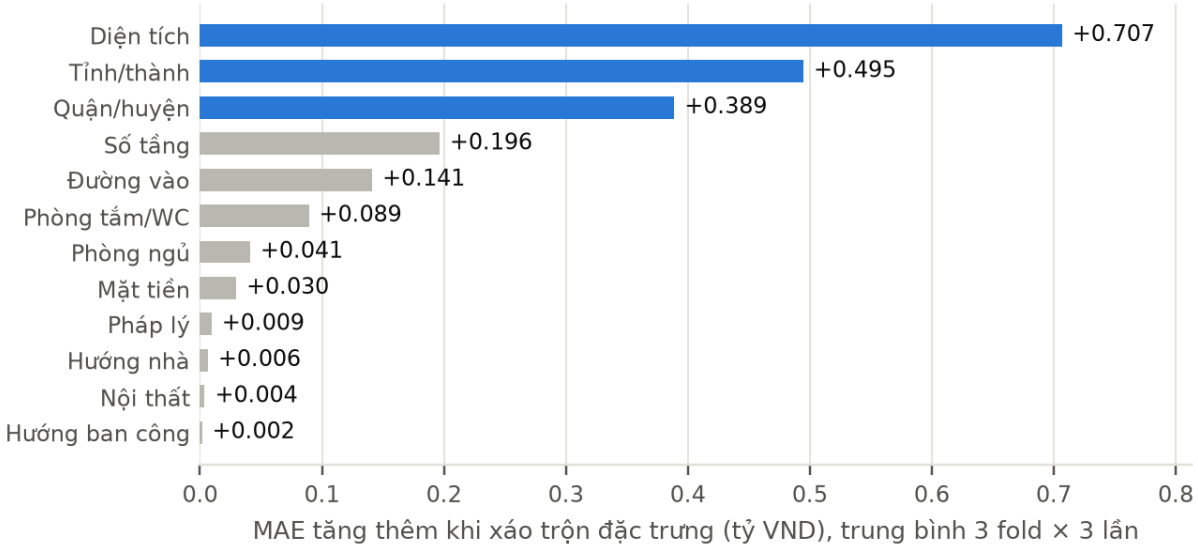
```
from xgboost import XGBRegressor
from sklearn.pipeline import Pipeline

model = XGBRegressor(
    n_estimators=3000,      # tran tren; so cay that chon bang early stopping
    learning_rate=0.05,
    max_depth=9,
    min_child_weight=1,
    subsample=0.8,
    colsample_bytree=0.7,
    tree_method="hist",
    eval_metric="mae",
    random_state=42,
)
pipeline = Pipeline([("preprocessing", preprocessing), ("model", model)])

# Trong moi fold cua 3-fold CV:
#   1. tach 15% phan fit de chon so cay (dung sau 100 vong khong cai thien)
#   2. refit voi so cay da chon tren toan bo phan fit
#   3. cham MAE, RMSE, R2 tren phan assessment cua fold
```

VII.3 Mô hình học được điều gì?

Nhóm đo *permutation importance* trên chính phần đánh giá của từng fold: xáo trộn giá trị một đặc trưng, giữ nguyên các đặc trưng khác, và đo MAE tăng thêm bao nhiêu. Cách đo này tính trên dữ liệu mô hình chưa thấy và cho kết quả theo 12 biến gốc thay vì 388 cột One-Hot.



Hình 8: Permutation importance của XGBoost (`splits_v2`, 3 fold × 3 lần xáo trộn)

- **Vị trí là nhóm quan trọng nhất:** xáo trộn đồng thời tỉnh và quận làm MAE tăng 0.867 tỷ VND, gần gấp đôi sai số hiện tại. Kết quả này đồng ý với H1 và phát hiện 1.
- **Diện tích đứng thứ hai về độ quan trọng riêng lẻ** (+0.707 tỷ VND), dù tương quan đơn biến chỉ 0.19. Mô hình học được đúng cơ chế "giá ≈ đơn giá khu vực × diện tích": diện tích chỉ có nghĩa khi đã biết vị trí. Đây là lời giải cho nghịch lý ở mục VI.2.
- **Kết cấu và hạ tầng**: số tầng (+0.196), đường vào (+0.141), phòng tắm (+0.089) xếp tiếp theo, khớp với H4 và với thực tế nhà phố nhiều tầng, ngõ ô tô vào được có giá cao hơn.
- **Pháp lý, hướng nhà, nội thất, hướng ban công** đều dưới 0.01 tỷ VND: khi đã biết vị trí và kết cấu, các biến này gần như không thêm thông tin. Nội thất có khác biệt đơn biến ($\delta = 0.23$) nhưng khác biệt đó đã được giải thích bởi các biến khác.

Quay về domain

Thứ hạng của mô hình trùng với cách một môi giới có kinh nghiệm định giá: hỏi "ở đâu" trước, rồi "bao nhiêu mét", rồi "mấy tầng, ngõ rộng không". Các yếu tố được nhắc nhiều trong tin rao như hướng nhà hay nội thất hầu như không làm thay đổi giá rao trong khoảng 1–11.5 tỷ VND.

VIII Evaluation

VIII.1 Chỉ số kỹ thuật

Mọi con số trong mục này là dự đoán *out-of-fold* trên 18 136 dòng train của `splits_v2`: mỗi dòng được dự đoán bởi pipeline của fold không chứa dòng đó. Nhóm đã tái lập lại đúng MAE và R^2 từng fold đã lưu trong checkpoint trước khi phân tích. XGBoost đạt MAE 0.984 tỷ VND, RMSE 1.319 tỷ VND, $R^2 = 0.645$; MAE từng fold nằm trong khoảng 0.978–0.992 tỷ VND. Khoảng cách train/CV (0.55 so với 0.98 tỷ VND) cho thấy mô hình còn overfit, nhưng early stopping đã giữ sai số trên dữ liệu chưa thấy ổn định.

Chưa phải kết quả nghiệm thu

Tập test và calibration chưa được dùng. CV score đã được dùng để chọn cấu hình nên có thể lạc quan nhẹ. Mục tiêu $R^2 \geq 0.7$ của dự án hiện **chưa đạt** trên CV (0.645); kết luận cuối cần một lần đánh giá duy nhất trên test sau khi khóa mô hình.

VIII.2 Chỉ số theo domain và giá trị thực tế

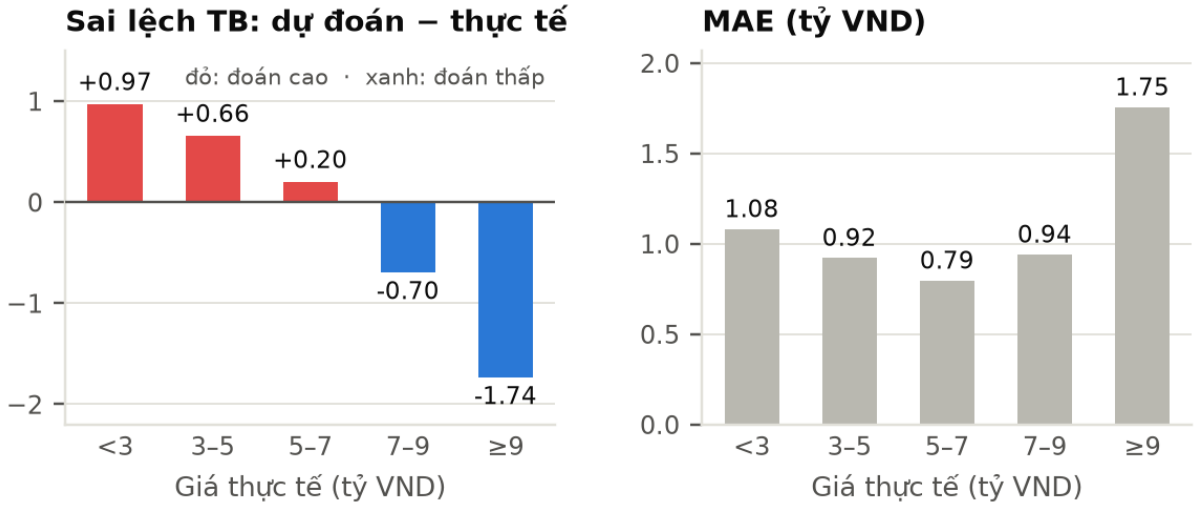
Người mua không hỏi "MAE bao nhiêu" mà hỏi "con số này lệch tối đa bao nhiêu phần trăm". Bảng dưới dịch kết quả sang các chỉ số đó và so với hai cách làm hiện tại, tính trên cùng các fold.

Bảng 16: Kết quả theo chỉ số domain (out-of-fold, 18 136 căn)

Chỉ số domain	Trung vị giá	Đơn giá quận × diện tích	LightGBM	XGBoost
% căn có sai số $\leq 10\%$	19.0%	28.9%	37.8%	**39.8%**
% căn có sai số $\leq 20\%$	36.8%	52.1%	65.4%	**66.9%**
Sai số tương đối trung vị (MdAPE)	26.9%	19.0%	13.9%	**13.3%**
% căn lệch quá 1 tỷ	68.3%	51.8%	40.1%	**38.1%**
MAE (tỷ VND)	1.845	1.545	1.016	**0.984**

So với quy tắc đơn giá quận × diện tích, XGBoost nâng tỷ lệ căn được ước lượng trong ±20% từ 52% lên 67% và giảm sai số tương đối trung vị từ 19% xuống 13%. Với một căn 6 tỷ VND, đó là chênh lệch giữa sai khoảng 1.1 tỷ VND và khoảng 0.8 tỷ VND ở trường hợp điển hình. Tuy vậy, cứ ba căn vẫn có một căn lệch hơn 20%, nên con số chỉ nên dùng làm điểm tham chiếu.

VIII.3 Error Analysis



Hình 9: Sai lệch trung bình (trái) và MAE (phải) của XGBoost theo nhóm giá thực tế (out-of-fold)

Bảng 17: Sai số XGBoost theo nhóm điều kiện (out-of-fold)

Nhóm	n	MAE	Sai lệch TB	MdAPE
Quận có ≥ 100 tin train	15 336	0.957	−0.01	12.7%
Quận có 30–99 tin	1 828	0.996	+0.02	15.9%
Quận có < 30 tin	972	1.379	+0.31	23.8%
Thiếu 0–2 trường tùy chọn	6 628	0.903	−0.02	12.9%
Thiếu 3–5 trường	8 179	0.968	+0.01	13.0%
Thiếu 6–9 trường	3 329	1.184	+0.07	15.4%
Diện tích < 50 m^2	7 165	0.892	+0.02	13.4%
Diện tích ≥ 200 m^2	428	1.504	−0.06	19.0%

Ba nhóm lỗi chính và nguyên nhân theo domain:

1. **Kéo về trung bình ở hai đầu giá.** Căn dưới 3 tỷ VND bị đoán cao trung bình 0.97 tỷ VND, căn từ 9 tỷ VND bị đoán thấp 1.74 tỷ VND. Hai căn cùng quận, cùng diện tích có thể chênh giá vì mặt đường hay ngõ sâu, nhà mới hay nhà cũ, những thông tin không có trong dữ liệu; mô hình vì thế dự đoán gần mức trung bình của nhóm. Dự đoán chỉ trải từ 0.14 đến 10.56 tỷ VND, hẹp hơn khoảng giá thật.

2. **Quận ít dữ liệu.** 972 căn ở các quận có dưới 30 tin train có MAE 1.38 tỷ VND và bị đoán cao (+0.31 tỷ VND): mô hình mượn mức giá của các quận đông dữ liệu, vốn đắt hơn.

3. **Tin khai báo thiếu và nhà rất rộng.** Thiếu 6–9 trường làm MAE tăng 31% so với tin khai báo gần đủ; nhà từ 200 m^2 có MAE 1.50 tỷ VND vì ít mẫu và đơn giá biến động mạnh ở vùng ven.

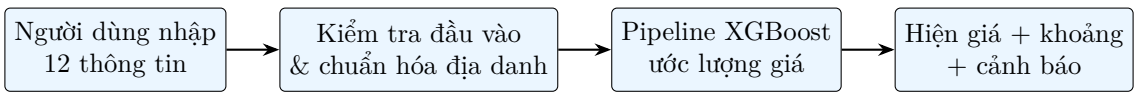
VIII.4 Kiểm chứng với chuyên gia domain

Nhóm chưa có buổi phỏng vấn môi giới hoặc thẩm định viên. Đối chiếu gián tiếp: thứ hạng đặc trưng (vị trí, diện tích, số tầng, đường vào) khớp với cách định giá theo phương pháp so sánh; chênh lệch đơn giá nội đô và vùng ven phù hợp với hiểu biết chung về thị trường. Bước tiếp theo là cho 3–5 môi giới xem 20 ước lượng ngẫu nhiên và ghi lại căn nào họ cho là sai, sai vì lý do gì.

IX Application & Recommendations

IX.1 Cách sử dụng kết quả

Nhóm đã xây dựng giao diện Streamlit (`app/streamlit_app.py`) cho người dùng phổ thông, toàn bộ tiếng Việt. Ứng dụng gọi mô hình qua một điểm duy nhất (`app/core/model_interface.py`); hiện chạy ở chế độ xem trước vì pipeline cuối chưa được khóa và xuất file.



Hình 10: Quy trình ước lượng giá trong ứng dụng

Người dùng nhập vị trí và đặc điểm căn nhà; các trường có tỷ lệ thiếu cao trong dữ liệu (hướng nhà, hướng ban công, nội thất) được để tùy chọn. Kết quả luôn hiển thị là *ước lượng*

giá rao, kèm đơn vị tỷ VND và các cảnh báo ở bảng dưới; không gọi là giá giao dịch hay giá thị trường.

IX.2 Khuyến nghị

Bảng 18: Khuyến nghị dựa trên data

Khuyến nghị	Căn cứ từ data	Người thực hiện	Tác động	Rủi ro
Bắt buộc nhập tỉnh và quận; gợi ý tên từ danh sách chuẩn hóa	Vị trí: importance 0.87 tỷ VND; 26 biến thể tên tỉnh	Nhóm app	Giảm lỗi lớn nhất	Quận mới chưa có trong danh sách
Cảnh báo khi quận có < 30 tin hoặc giá dự đoán ngoài 1–11.5 tỷ VND	MAE 1.38 ở quận ít tin; dự đoán thấp nhất 0.14 tỷ VND	Nhóm app	Tránh tin nhầm con số yếu	Người dùng bỏ qua cảnh báo
Hiện khoảng giá thay vì một con số, hiệu chỉnh trên tập calibration	Sai lệch $+0.97$ / -1.74 tỷ VND ở hai đầu	Nhóm model	Phản ánh đúng độ bất định	Khoảng quá rộng ở nhóm hiếm
Người mua: so giá rao với khoảng ước lượng, đặc biệt nhà diện tích lớn	Nghịch lý diện tích; MdAPE 13%	Người dùng	Có cơ sở thương lượng	Thiếu thông tin chất lượng nhà
Người bán, môi giới: khai báo đủ số tầng, WC, đường vào	Thiếu 6–9 trường: MAE tăng 31%	Người bán	Ước lượng sát hơn	Khai báo sai

IX.3 Giám sát và cập nhật

- **Trước khi phát hành:** khóa cấu hình XGBoost, refit trên train + validation, hiệu chỉnh khoảng dự đoán trên calibration, đánh giá một lần trên test (MAE, RMSE, R^2, độ phủ của khoảng).
- **Drift dữ liệu đầu vào:** theo dõi phân bố tỉnh/quận, diện tích và tỷ lệ bỏ trống của người dùng so với tập train; tỷ lệ quận "chưa từng thấy" tăng là tín hiệu cần bổ sung dữ liệu.
- **Drift giá:** dữ liệu là ảnh chụp năm 2024; khi có tin rao mới, so trung vị đơn giá theo quận với dữ liệu cũ. Nếu lệch hơn 10% ở các quận lớn, huấn luyện lại thay vì tiếp tục dùng mô hình cũ.

X Limitations & Future Work

- **Giới hạn dữ liệu:** giá rao, không phải giá giao dịch; chỉ khoảng 1–11.5 tỷ VND, nên mô hình không có cơ sở cho nhà rẻ hơn hoặc đắt hơn; 74% tin ở Hà Nội và TP.HCM; một thời điểm năm 2024. Đơn vị của diện tích, mặt tiền, đường vào chưa được nguồn mô tả rõ.
- **Thông tin thiếu:** không có tọa độ, tên đường cụ thể, năm xây dựng, loại hình (nhà dự án/thổ cư, mặt phố/trong ngõ). Đây là nguyên nhân chính của hiện tượng kéo về trung bình.
- **Đánh giá chưa hoàn tất:** chưa đánh giá trên test, chưa hiệu chỉnh khoảng dự đoán, R^2 CV 0.645 chưa đạt mục tiêu 0.7; chưa phỏng vấn chuyên gia domain.

- **Giả định chưa kiểm chứng:** mỗi dòng là một căn nhà riêng (202 dòng trùng thuộc tính chưa xác minh); mối quan hệ giữa các biến giữ nguyên khi thị trường thay đổi sau 2024.

Hướng phát triển:

1. Thêm đặc trưng vị trí chi tiết hơn: `City_District`, target encoding đơn giá theo quận có làm mượt cho quận ít tin, hoặc tọa độ khi có địa chỉ đầy đủ.
2. Huấn luyện trên log giá hoặc dùng quantile regression để giảm kéo về trung bình và tạo khoảng dự đoán.
3. Ensemble XGBoost + LightGBM, phân tích SHAP cho từng ước lượng để giải thích trong ứng dụng.
4. Thu thập dữ liệu mới có ngày đăng để đo biến động giá theo thời gian; kiểm chứng với môi giới.

A Data Dictionary đầy đủ

Bảng 19: Toàn bộ biến trong dữ liệu sau khi tách địa chỉ (% thiếu trên 30 229 dòng gốc)

Biến	Kiểu	Đơn vị	Ý nghĩa, giá trị	% thiếu
`Price`	Số thực	tỷ VND	Tổng giá rao; 1.0–11.5	0.0
`Area`	Số thực	m^2	Diện tích ghi trên tin; 3.1–595	0.0
`Frontage`	Số thực	m	Mặt tiền; 1–77 (giá trị gốc)	38.3
`Access Road`	Số thực	m	Độ rộng đường vào; 1–85	44.0
`Floors`	Số nguyên	tầng	1–10	11.9
`Bedrooms`	Số nguyên	phòng	1–9	17.1
`Bathrooms`	Số nguyên	phòng	1–9	23.4
`House direction`	Phân loại	–	8 hướng (Đông, Tây - Nam, ...)	70.3
`Balcony direction`	Phân loại	–	8 hướng	82.6
`Legal status`	Phân loại	–	`Have certificate`, `Sale contract`	14.9
`Furniture state`	Phân loại	–	`Full`, `Basic`	46.7
`City`	Phân loại	–	Phần cuối của `Address`; 106 tên gốc	0.0
`District`	Phân loại	–	Phần áp chót của `Address`; 341 tên gốc	0.0
`row_id`	Số nguyên	–	Khóa truy vết dòng; không phải đặc trưng	0.0

B Reproducibility & Code Structure

- **Seed:** 42 cho chia tập, fold CV, chia trong fold để early stopping và mô hình.
- **Phiên bản thư viện:** Python 3.14; numpy 2.5.3; pandas 3.0.6; scikit-learn 1.9.1; xgboost 3.4.1; lightgbm 4.7.0; catboost 1.2.10; joblib 1.6.0.
- **Dữ liệu:** `splits_v2` được tạo lại từ `splits_v1` bằng script `src/preprocessing/repair_input_v2.py` đi kèm checkpoint (tham số `--project-root` là thư mục repo); tập train có SHA-256 bắt đầu bằng `bcbc0634`, đã đối chiếu khớp với manifest của checkpoint.
- **Checkpoint:** `models/candidates/milestone_v2_r2_2026-10-16/` chứa 3 pipeline CV của mỗi mô hình (không phải mô hình final), kèm manifest, chỉ số từng fold và mã tiền xử lý.

Cấu trúc thư mục repo

```
AIQS-Real-Estate-Price-Prediction/
|-- data/
|   |-- vietnam_housing_dataset.csv    # du lieu goc, khong sua
|   |-- _v1.csv                         # sau khi tach dia chi
|   `-- processed/splits_v1/            # train/validation/calibration/test
|-- notebooks/
|   |-- cleandata_estate_aiqs.ipynb     # lam sach, tach Address
|   |-- 01_data_handoff_and_split.ipynb
|   |-- 02_baseline_models.ipynb        # Dummy, Linear, Random Forest
|   `-- 03_model_experiments.ipynb      # boosting, CV, grid search
|-- experiments/                        # ket qua CV va grid search (CSV)
|-- models/candidates/                  # checkpoint XGBoost, LightGBM
|-- app/
|   |-- streamlit_app.py                # giao dien nguoi dung
|   `-- core/                           # schema, validation, model_interface
|-- reports/application_report/         # bao cao nay: main.tex, def.tex,
|                                       #   title.tex, IMG/ (logo + hinh)
`-- README.md
```